Fundamentos de la programación estadística y Data Mining en R

Unidad 1. - Introducción (brevísima) a ggplot2

Dr. Germán Rosati (CONICET - UNSAM - UNTREF)

21 marzo, 2019

¿Qué es ggplot?

- Es un paquete de R que permite crear gráficos bastante más bonitos que los que se pueden generar con la libería base de R.
- Se basa en la teoría de la "Gramática de Gráficos" -Grammar of Graphics -de Wilkinson, Leland (2005)-
- Provee un enfoque unificado y estadísticamente orientado para la generación de visualizaciones
- Logra esto gracias al uso de objetos más "abstractos" que los objetos gráficos "elementales" de R.

Usando (rápidamente) ggplot2

- Al menos tres formas
  - `qplot`
  - `ggplot + geom_xxx`
  - `ggplot + layer`
- Nos enfocamos en la segunda.

Ejemplo rápido

- Usamos el dataset `diamonds`
- Subseteamos una parte del dataset

```
library(ggplot2)
data(diamonds)
set.seed(42)
small<-diamonds[sample(nrow(diamonds),1000),]
head(small)
## # A tibble: 6 x 10
##   carat cut       color clarity depth table price     x
##   <dbl> <ord>     <ord> <ord>   <dbl> <dbl> <int> <dbl> <db
## 1  0.71 Very Good H     SI1      62.5    60  2096  5.68  5.
## 2  0.79 Premium   H     SI1      61.8    59  2275  5.97  5.
## 3  1.03 Ideal     F     SI1      62.4    57  6178  6.48  6.
## 4  0.5  Ideal     E     VS2      62.2    54  1624  5.08  5.
## 5  0.27 Ideal     E     VS1      61.6    56   470  4.14  4.
## 6  0.3  Premium   E     VS2      61.7    58   658  4.32  4.
```

Ejemplo rápido

- Veamos un ejemplo para la sintaxis de ggplot2:

```
ggplot(small) +
        geom_point(aes(x=carat,y=price,colour=cut)) +
        scale_y_log10() +
        facet_wrap(~cut) +
        ggtitle("First example")
```

- La instrucción anterior nos devuelve. . .

Ejemplo rápido

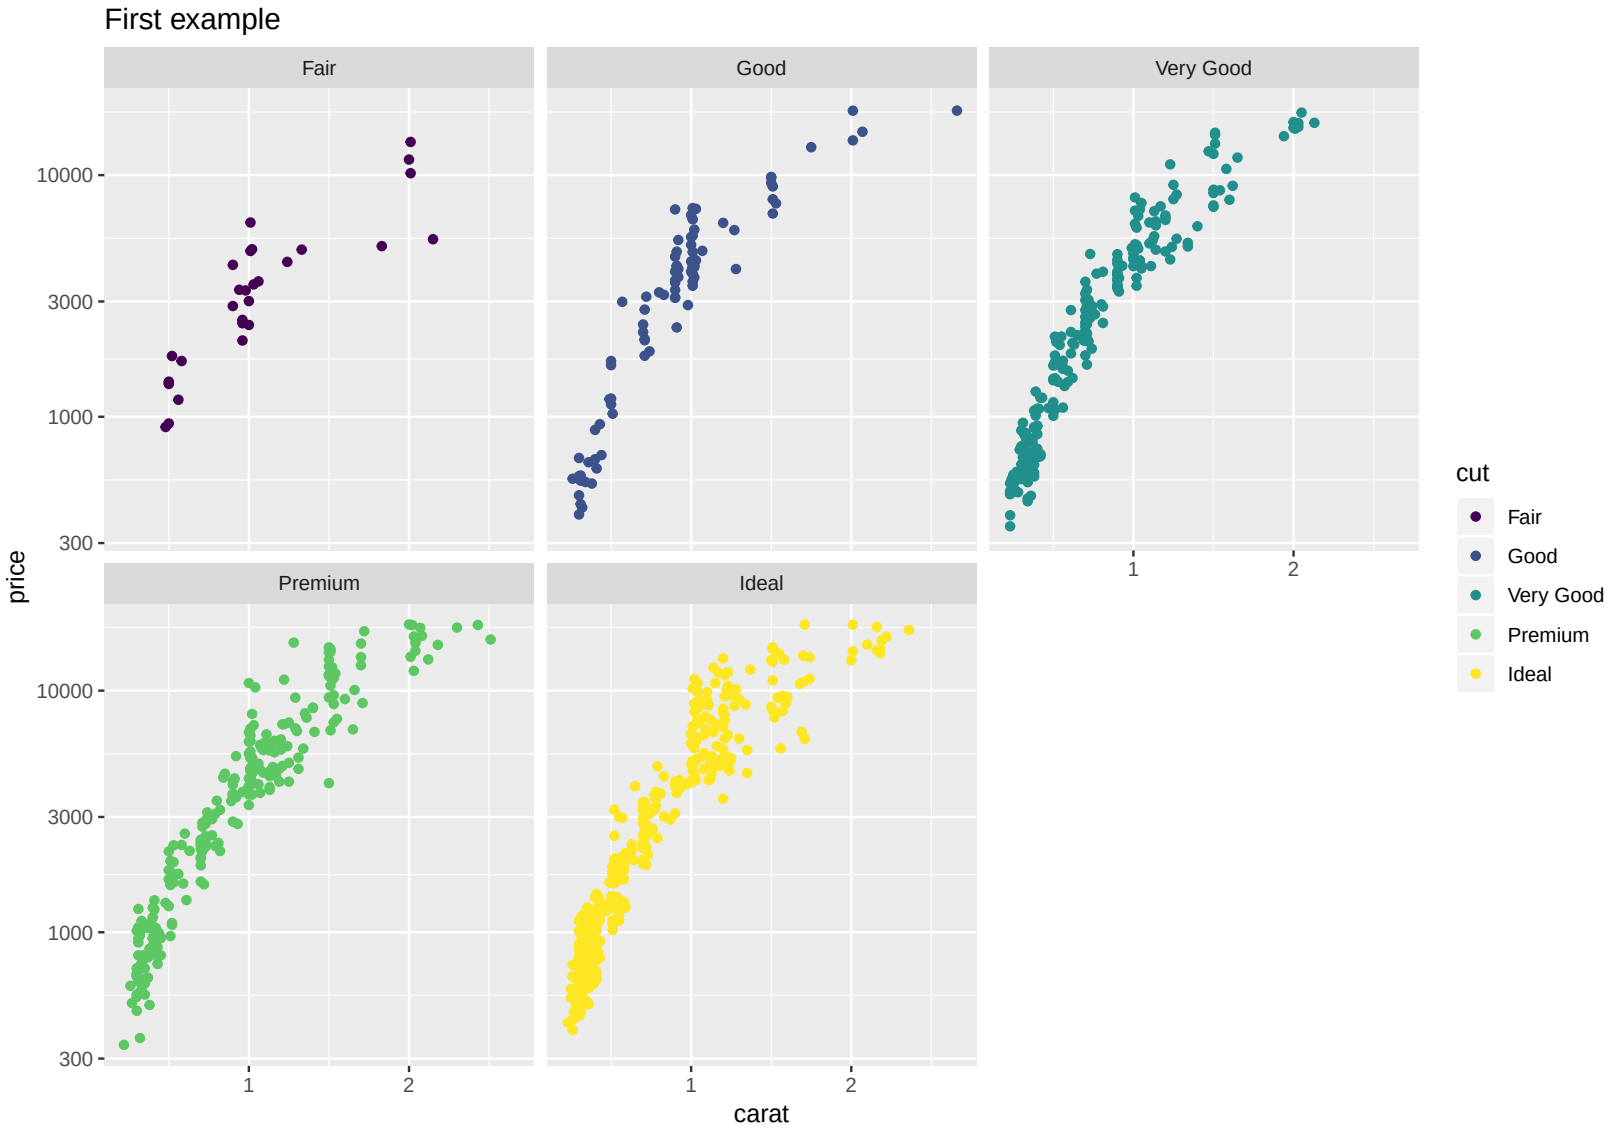

Ejemplo rápido: descomponiendo el código

1. Creamos el objeto ggplot y lo "llenamos" con los datos (siembre deberá ser un dataframe)

```
ggplot(small) +
```

2. Agregamos una capa estética (en este caso, de puntos)

```
geom_point(aes(x=carat,y=price,colour=cut)) +
```

3. "Facets": se usa para condicionar sobre variables

```
  facet_wrap(~cut) +
```

4. "Scales": se usa para definir escalas de las dimensiones, paletas de color, etc.

```
  scale_y_log10()
```

Mapeo de estética

- Todos los `geom_xxx()` requieren alguna capa referida a estética. Cada variable se "mapea" con alguna estética.
- Para ello se usa la función `aes`: `geom_point(aes(x = var))`
- Se pueden usar las siguientes:
  - x: x position (required)
  - y: y position (required)
  - shape: shape of point
  - colour: border colour
  - size: size
  - fill: internal colour
  - alpha: transparency

Mapeo de estéticas

- Por eso usamos

```
ggplot(small) +
        geom_point(aes(x=carat,y=price,colour=cut))
```

- También serían posibles otras formas:

```
ggplot(small,aes(x=carat,y=price,colour=cut)) +
        geom_point()

ggplot(small,aes(x=carat,y=price)) +
        geom_point(aes(colour=cut))
```

Mapeo de estéticas: una sutileza

- Hay una diferencia entre setear y asignar estéticas.
- La asignación (o "mapping") se hace a través de aes

```
p + geom_point(aes(x=carat,y=price,colour=cut))
```

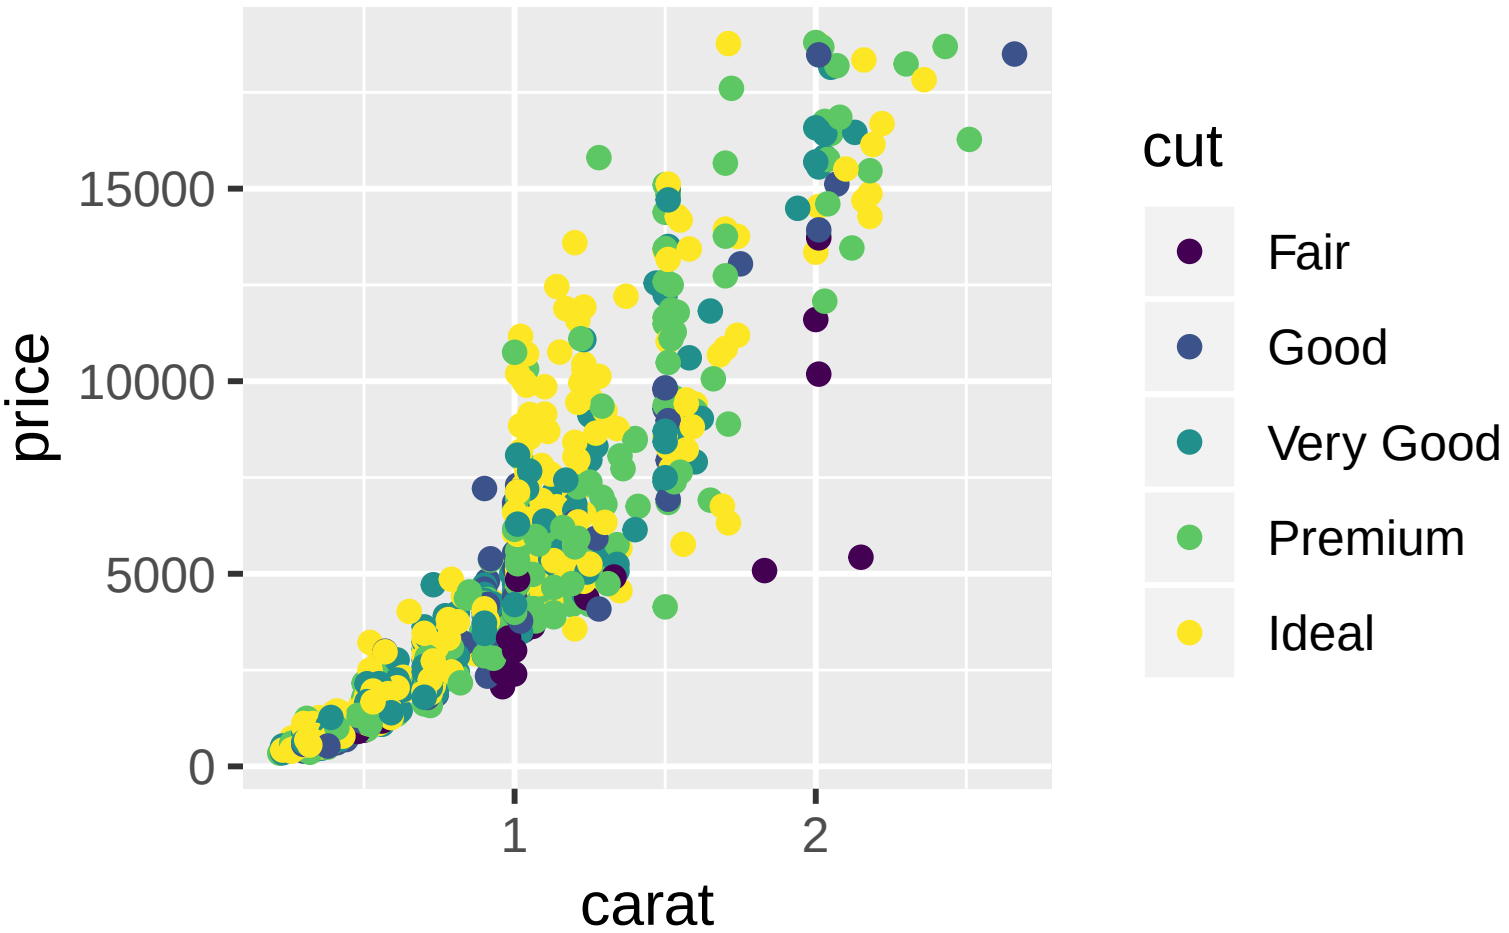

Mapeo de estéticas: una sutileza

- Pero el "setting" es decir, el hecho de fijar un valor a un determinado parámetro fijo se hace *fuera* de `aes`

```
p + geom_point(aes(x=carat,y=price), colour="blue")
```

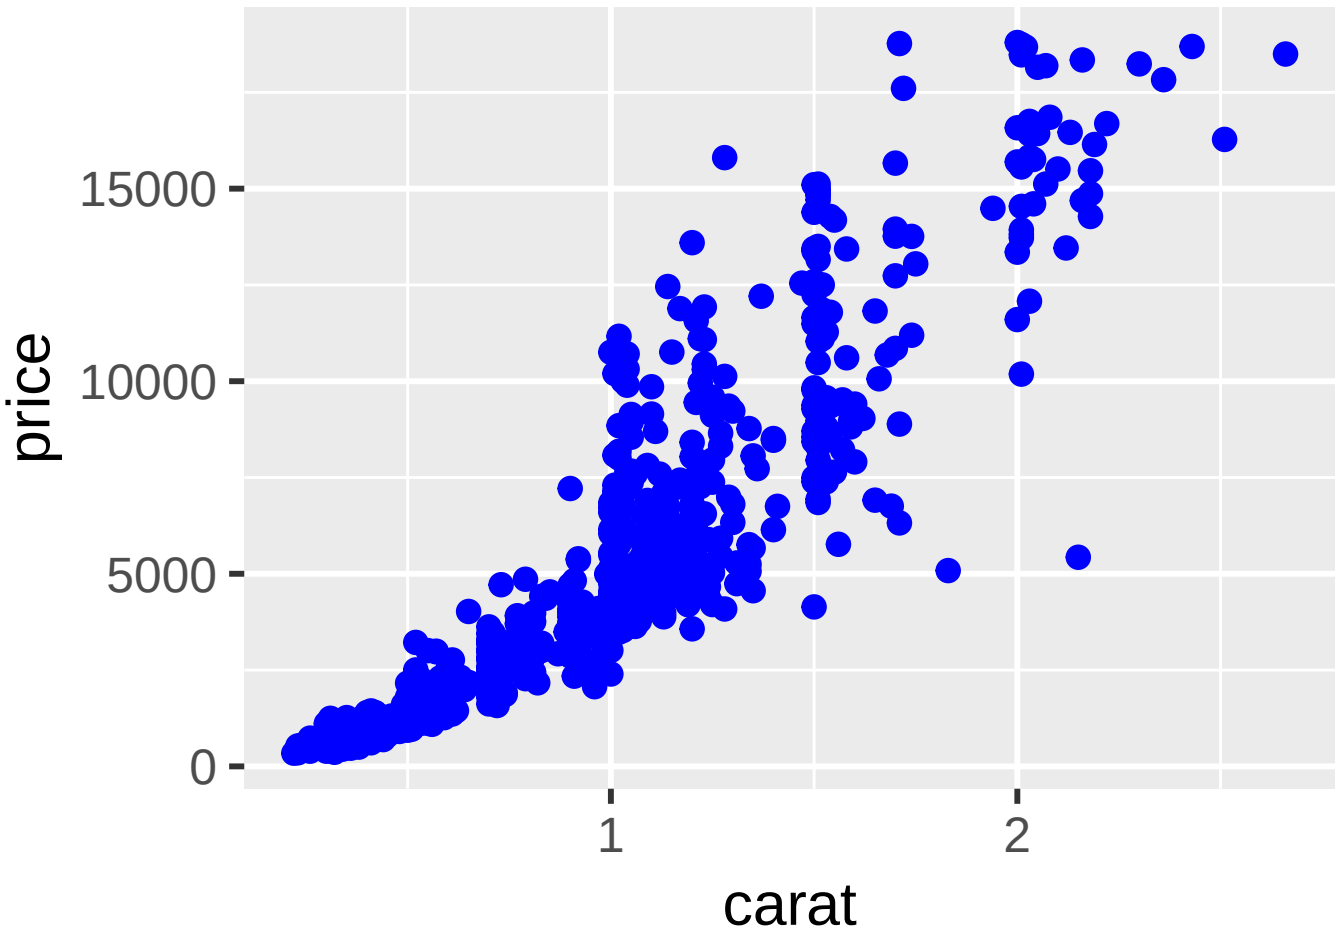

Mapeo de estéticas: una sutileza

- Tratar de fijar una estética dentro de aes ambas formas puede traer resultados inesperados:

```
p + geom_point(aes(x=carat,y=price,colour="blue"))
```

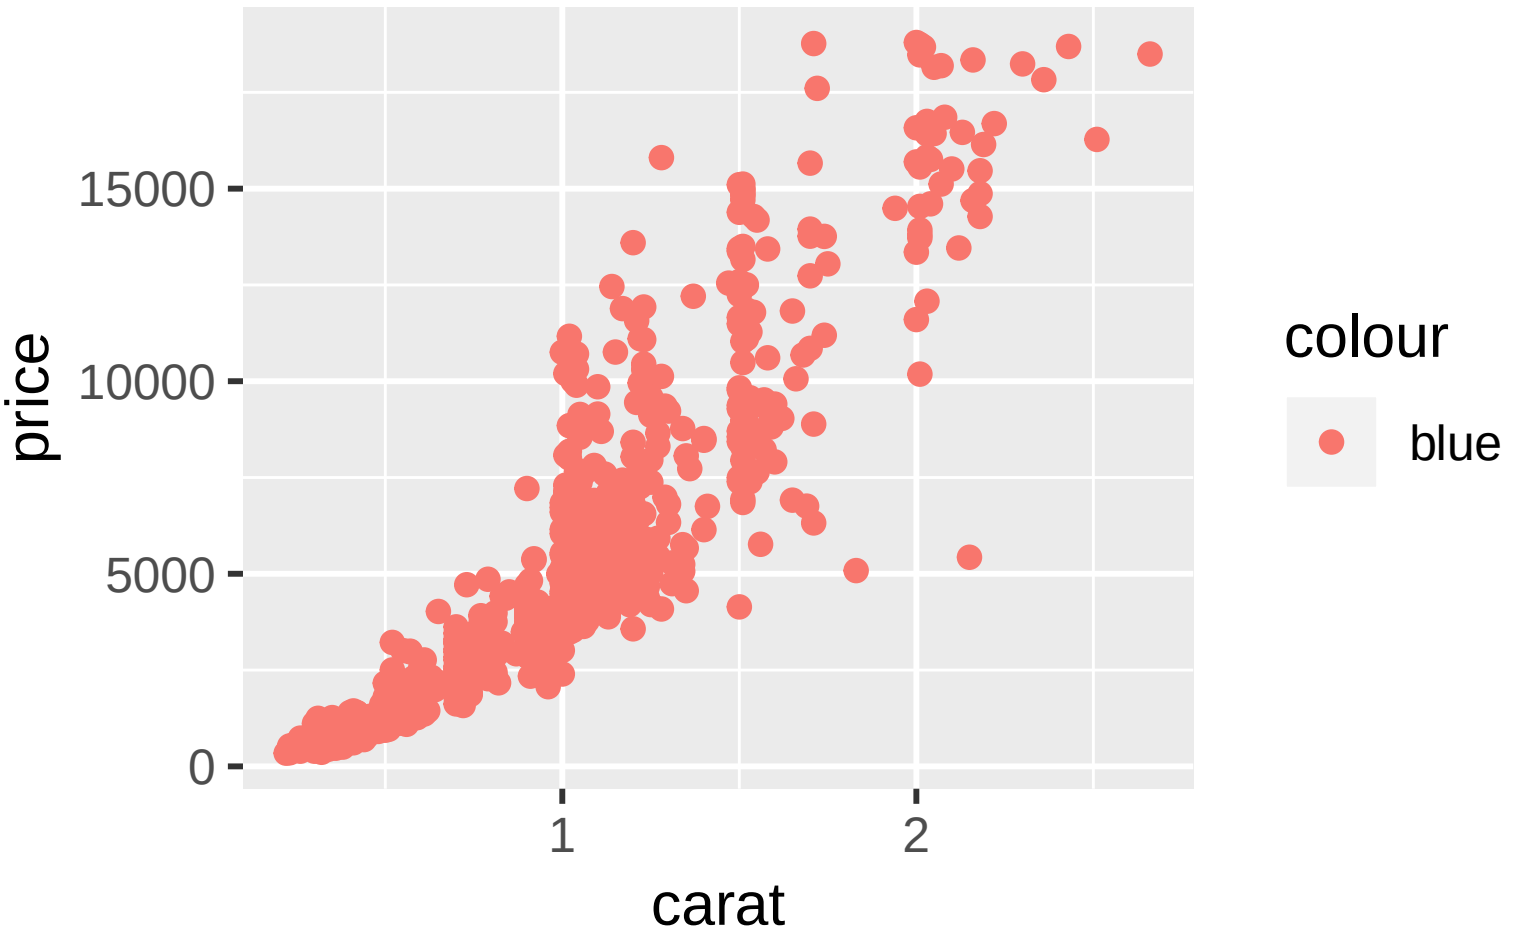

Faceting: condicionando sobre variables

- `facet_xxx` se usa para condicionar sobre 1 o 2 varibles. Es decir, para producir un gráfico difernete para cada valor de la variable en `facet_xxx`. Veamos sobre la variable `cut`:

```
p + geom_point(aes(x=carat,y=price)) +
  facet_wrap(~cut)
```

Faceting: condicionando sobre variables

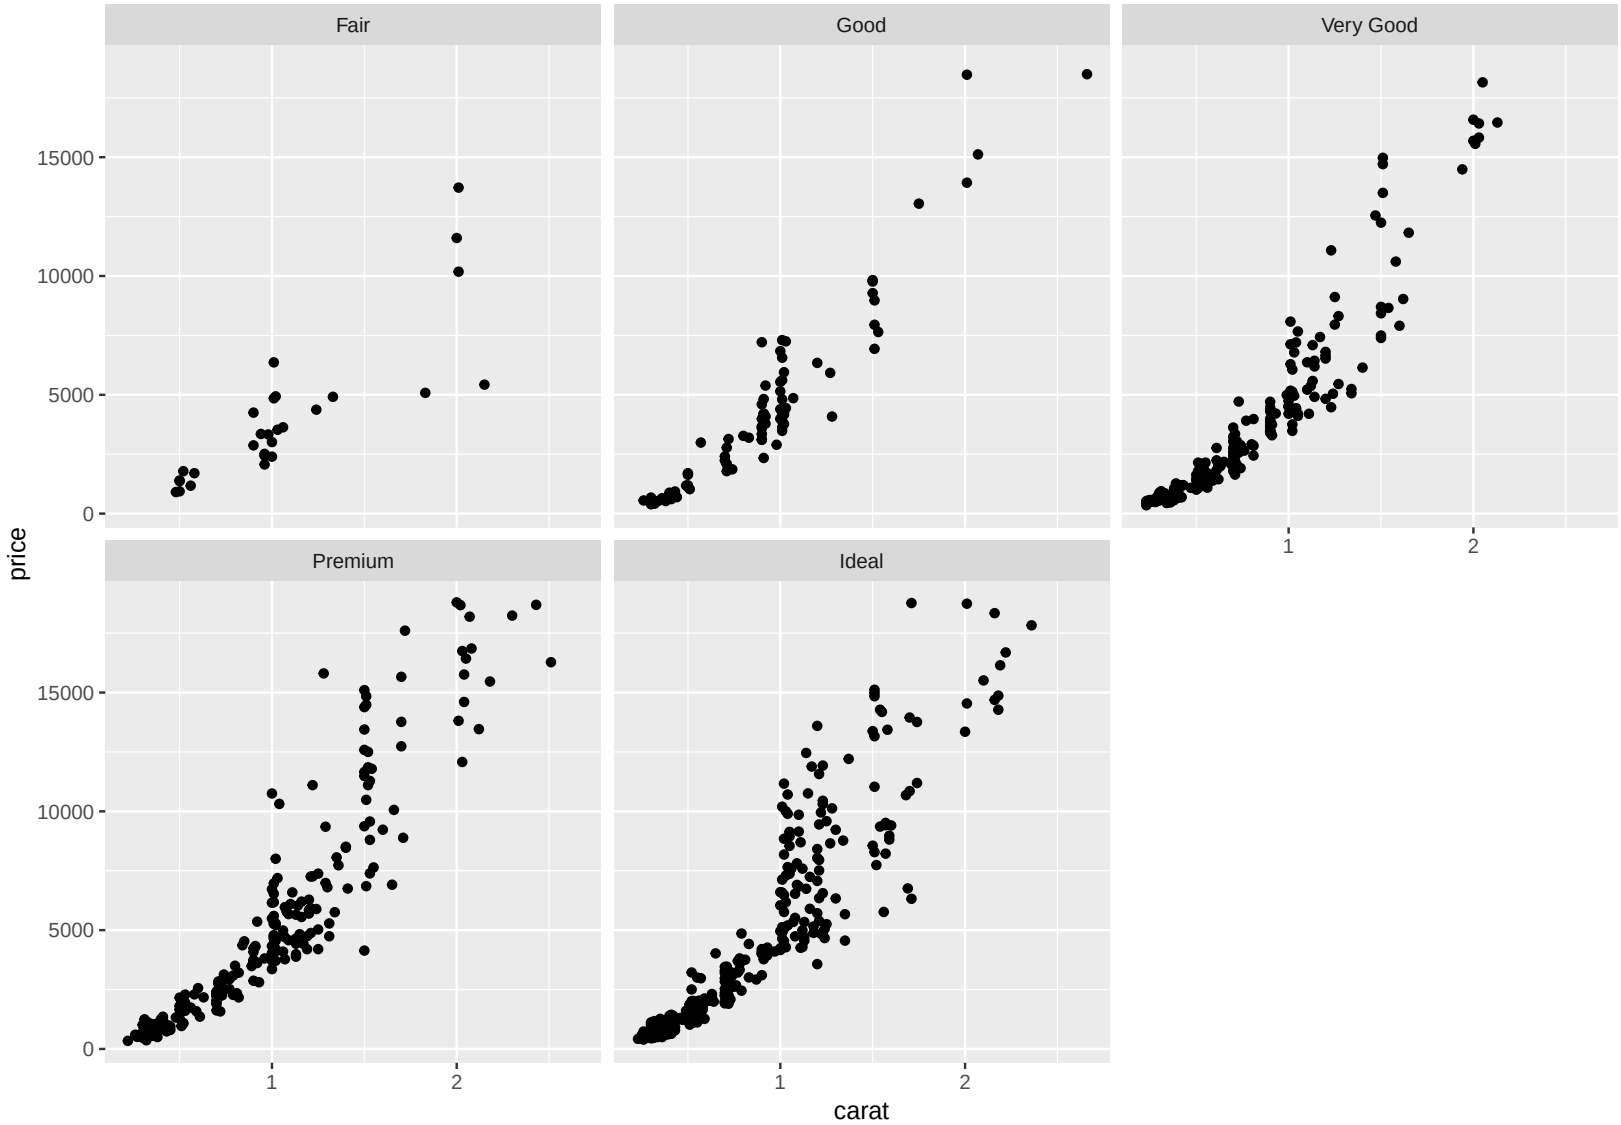

Faceting: condicionando sobre variables

- Con el argumento `nrow=1` generamos todos los gráficos sobre una sola fila.

```
p + geom_point(aes(x=carat,y=price)) +
  facet_wrap(~cut, nrow=1)
```

Faceting: condicionando sobre variables

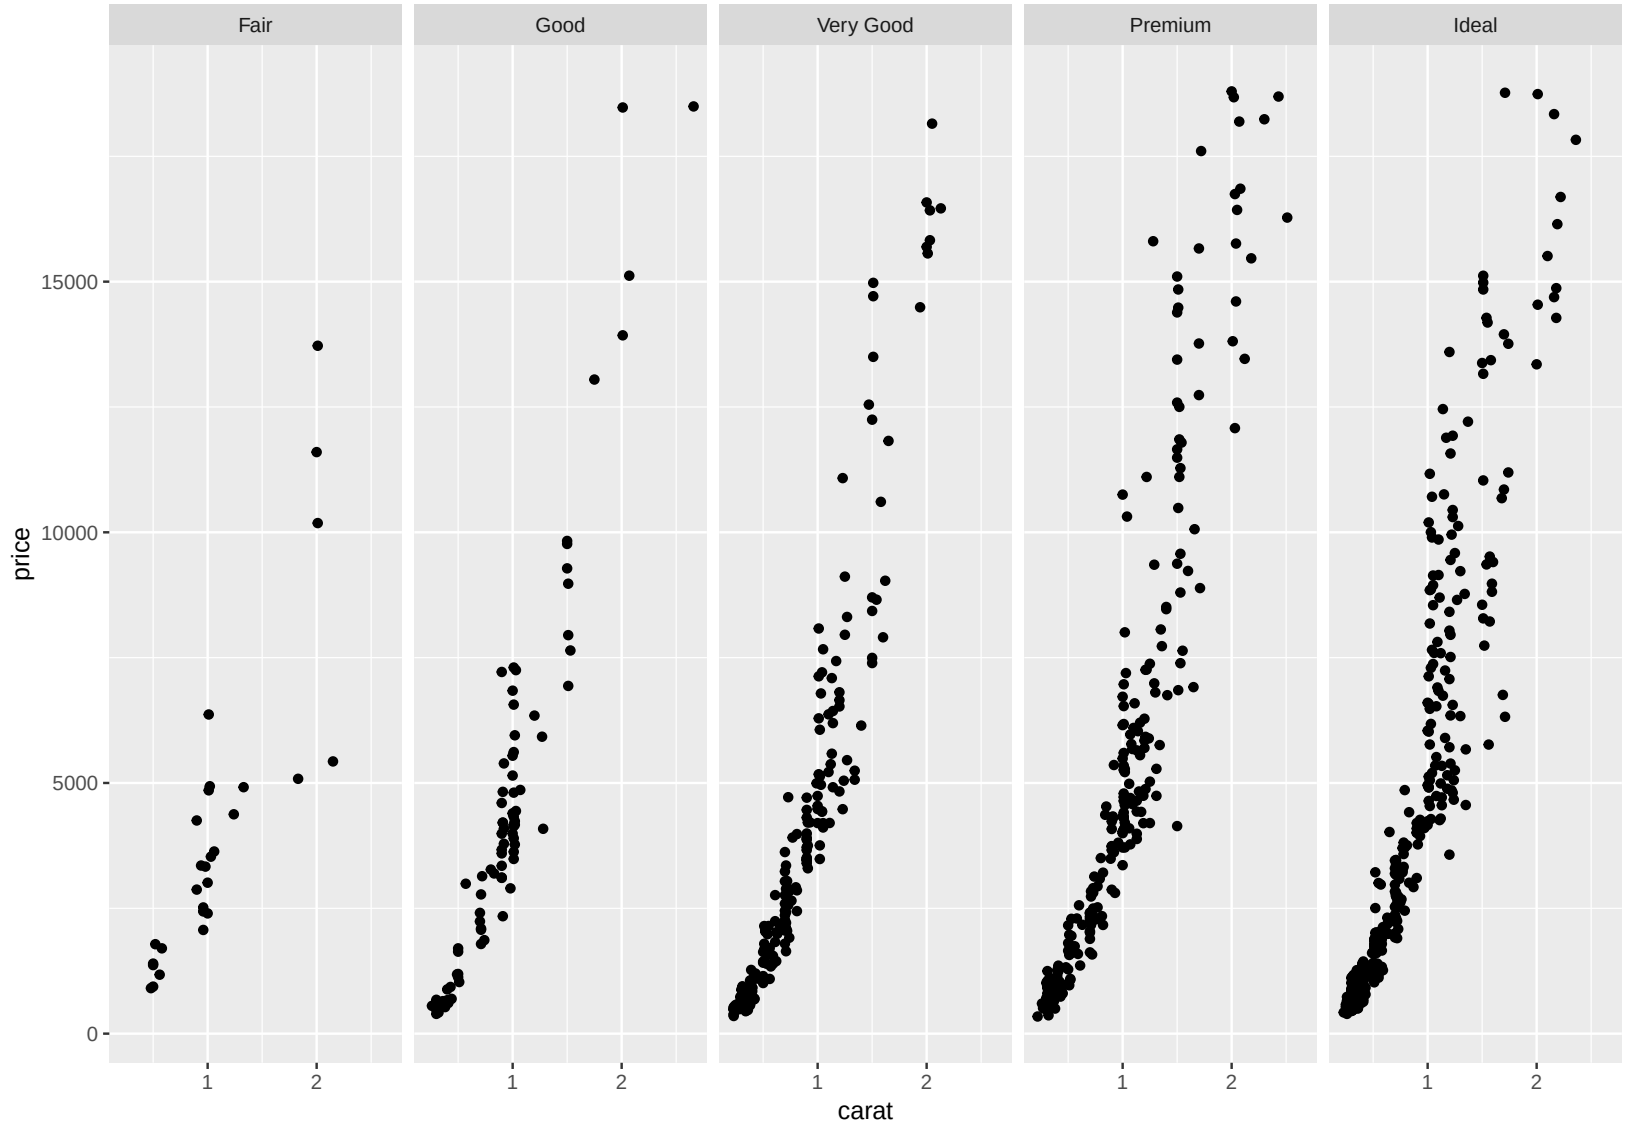

Faceting: condicionando sobre variables

- Con el argumento `ncol=1` generamos todos los gráficos sobre una sola columna.

```
p + geom_point(aes(x=carat, y=price)) +
  facet_wrap(~cut, ncol=1)
```

Faceting: condicionando sobre variables

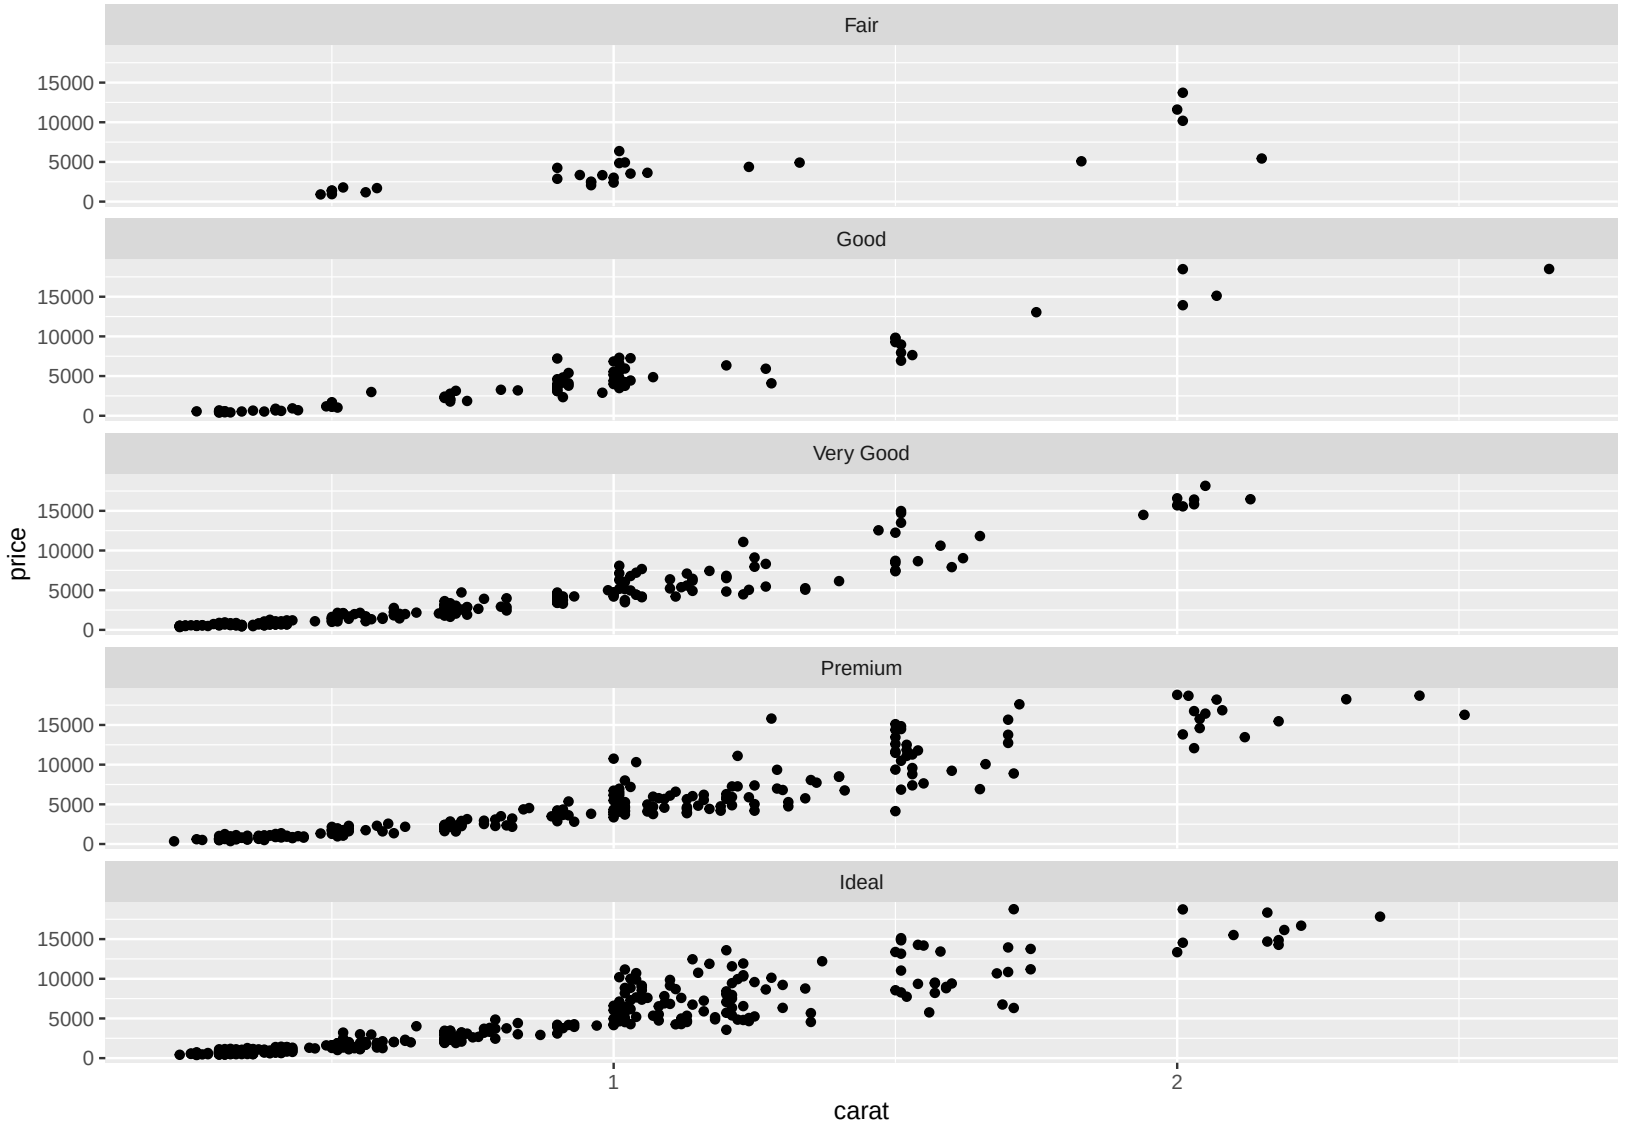

Faceting: condicionando sobre variables

- Usando la estética `facet_grid(cut~color)` generamos una grilla con los valores de `cut` y `color` y ploteamos un gráfico scatter para cada elemento de la grilla.

```
p + geom_point(aes(x=carat,y=price)) +
  facet_grid(cut~color)
```

Faceting: condicionando sobre variables

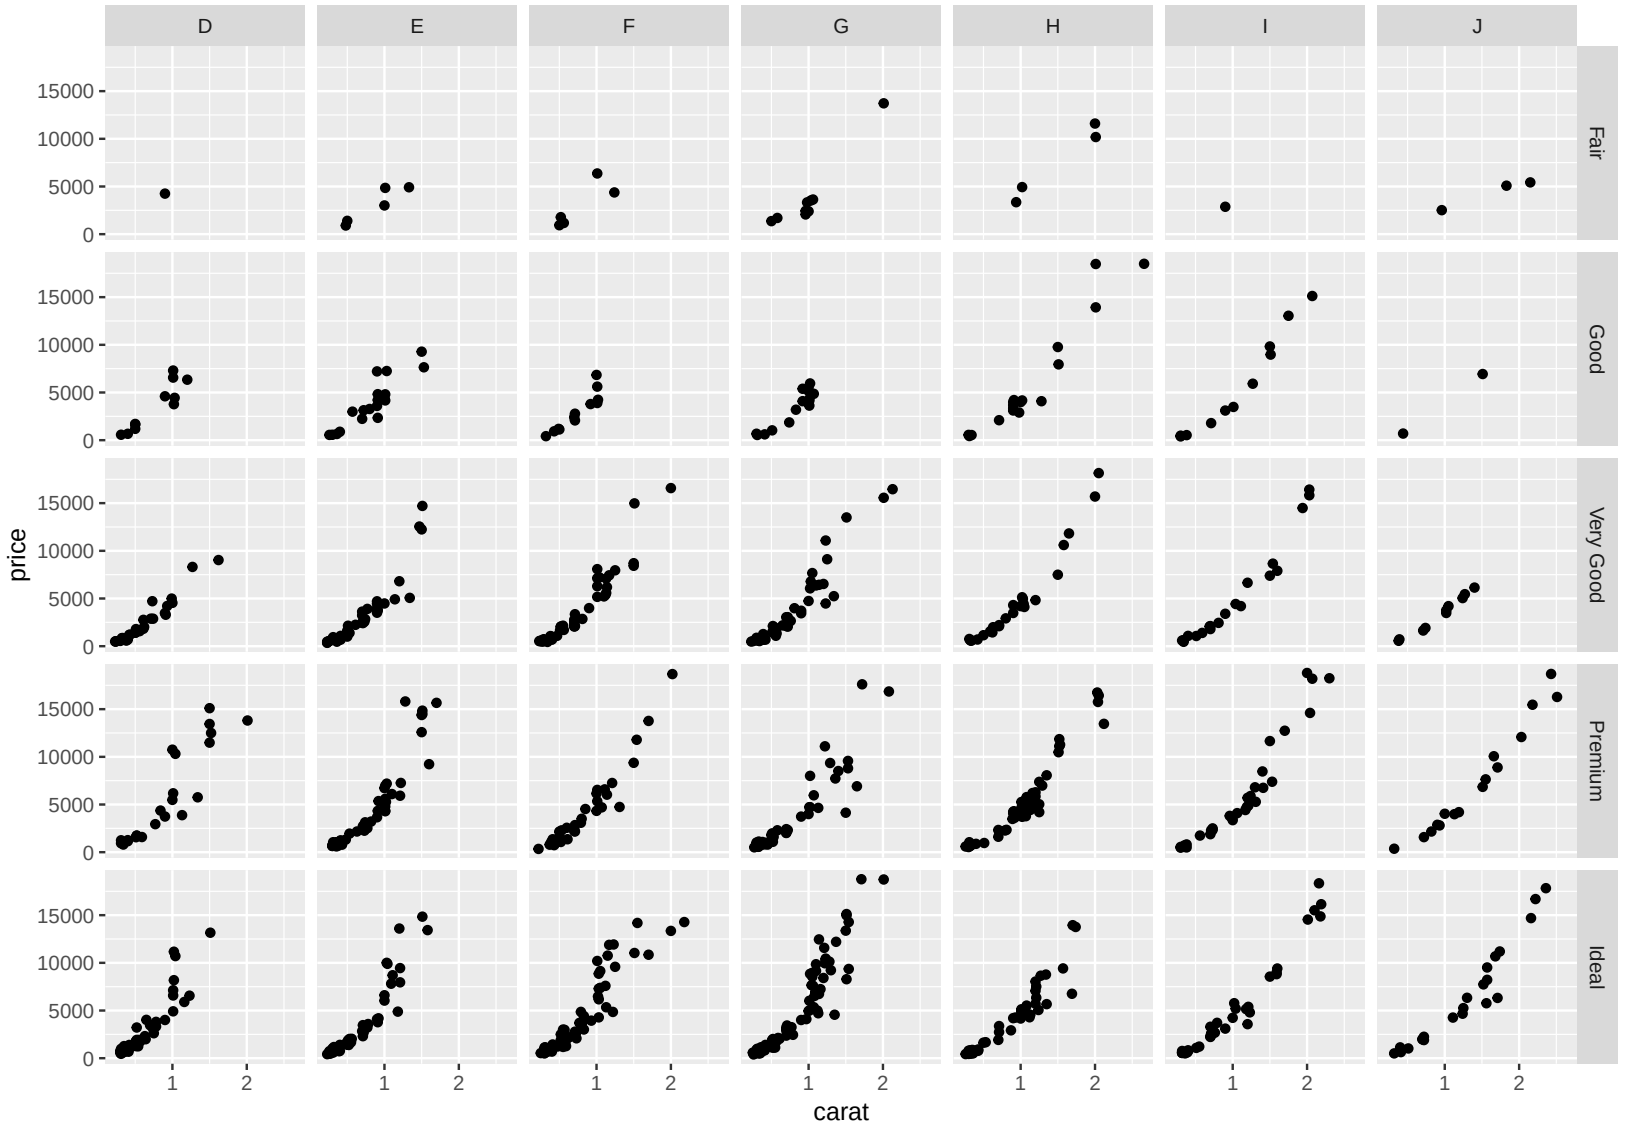

Otras geometrías: geom_smooth

- geom_smooth se usa para desplegar alguna línea de tendencia en los datos.
- Por defecto, usa un método llamado splines.

```
p <- ggplot(small,aes(x=carat,y=price))
p + geom_point() +
  geom_smooth() +
  facet_wrap(~cut)
```

Otras geometrías: geom_smooth

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```

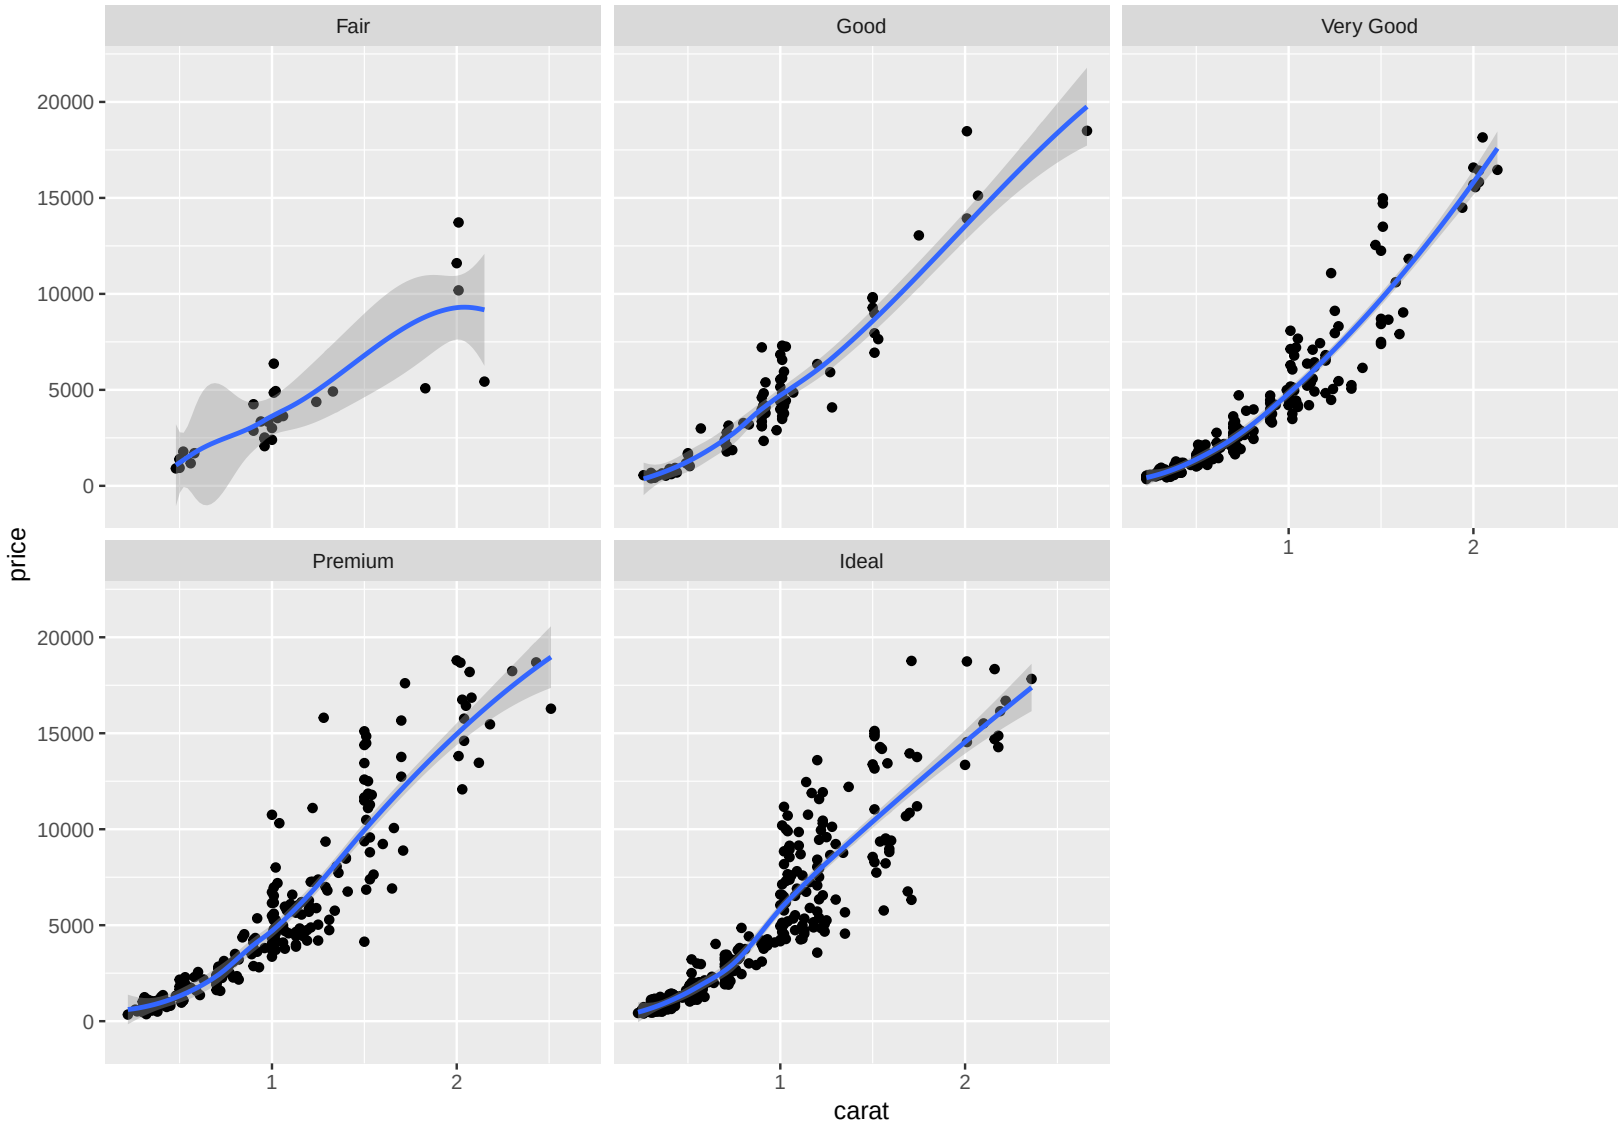

Otras geometrías: `geom_smooth`

- También se puede especificar alguna función para usar: en este caso una regresión lineal con `method='lm'`

```
p + geom_point() +
        geom_smooth(method="lm") +
        facet_wrap(~cut)
```

Otras geometrías: `geom_smooth`

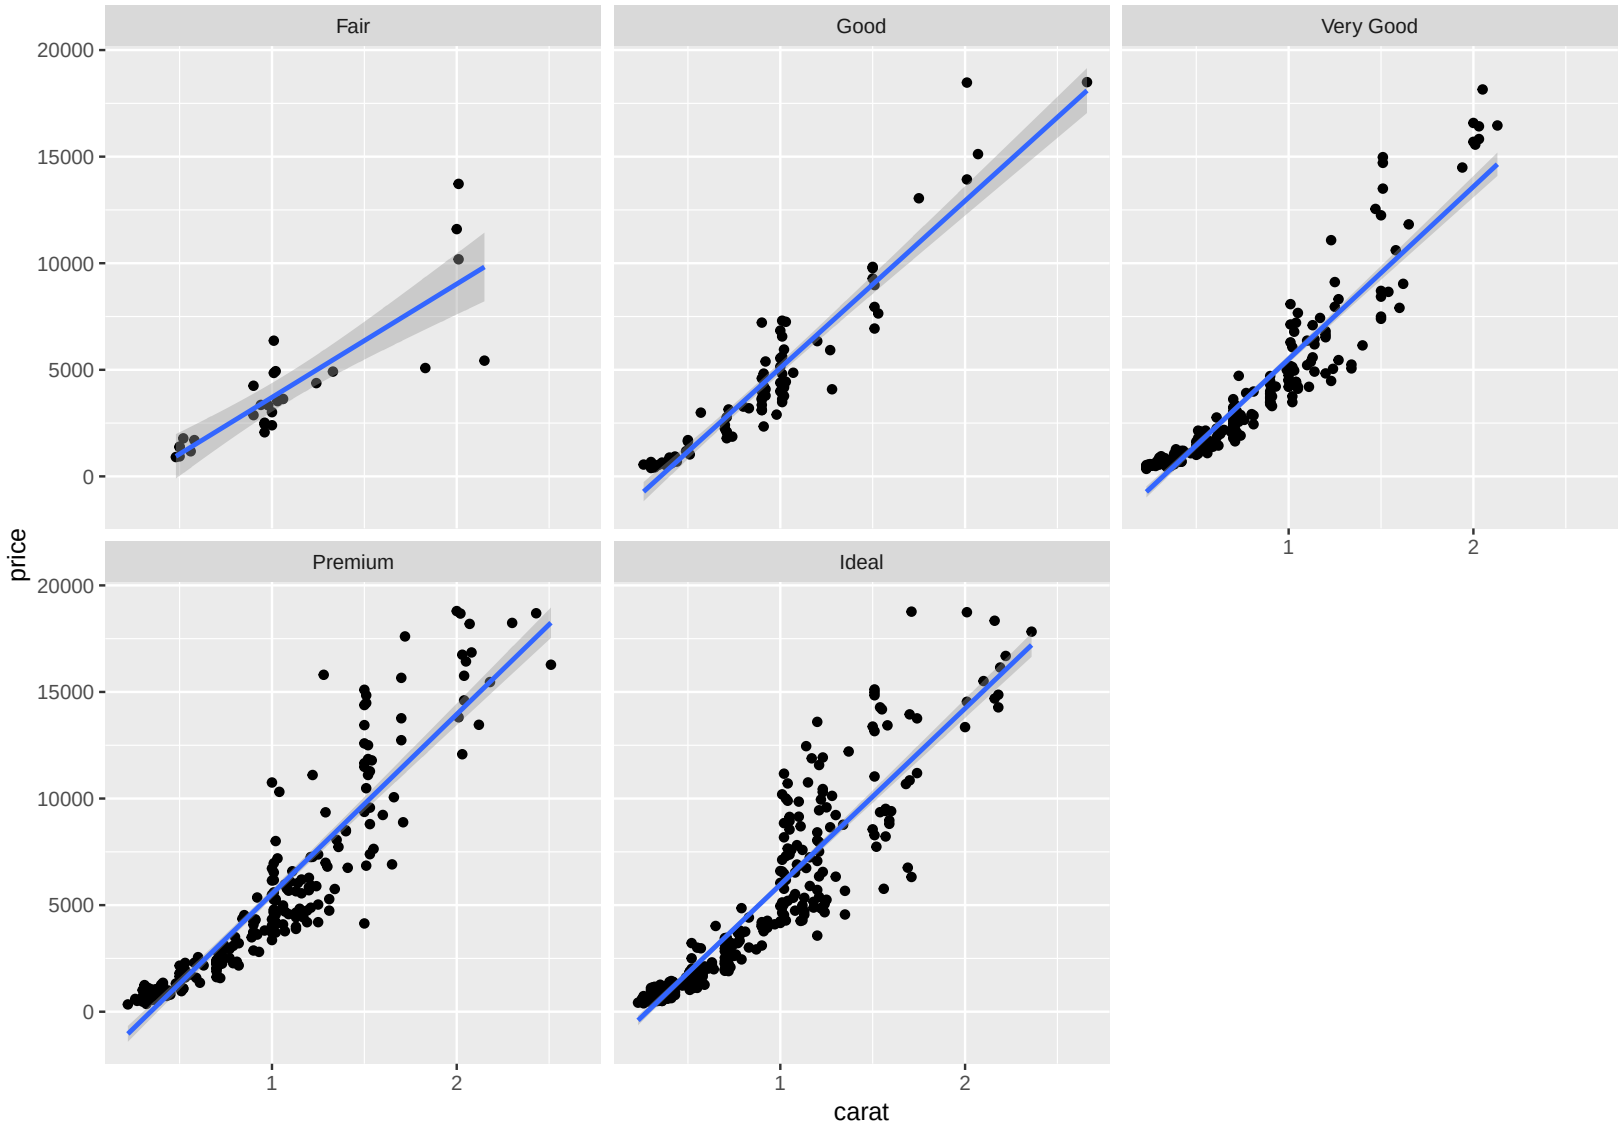

Otras geometrías: geom_smooth

- Pasemos en limpio...

```
p <- ggplot(diamonds, aes(x=carat, y=price, colour=cut))
p <- p + scale_x_log10() + scale_y_log10()
p <- p + geom_point(alpha=0.3) +
         geom_smooth(method='loess', colour='black')
p <- p + facet_wrap(~cut)
print(p)
```

Otras geometrías: `geom_smooth`

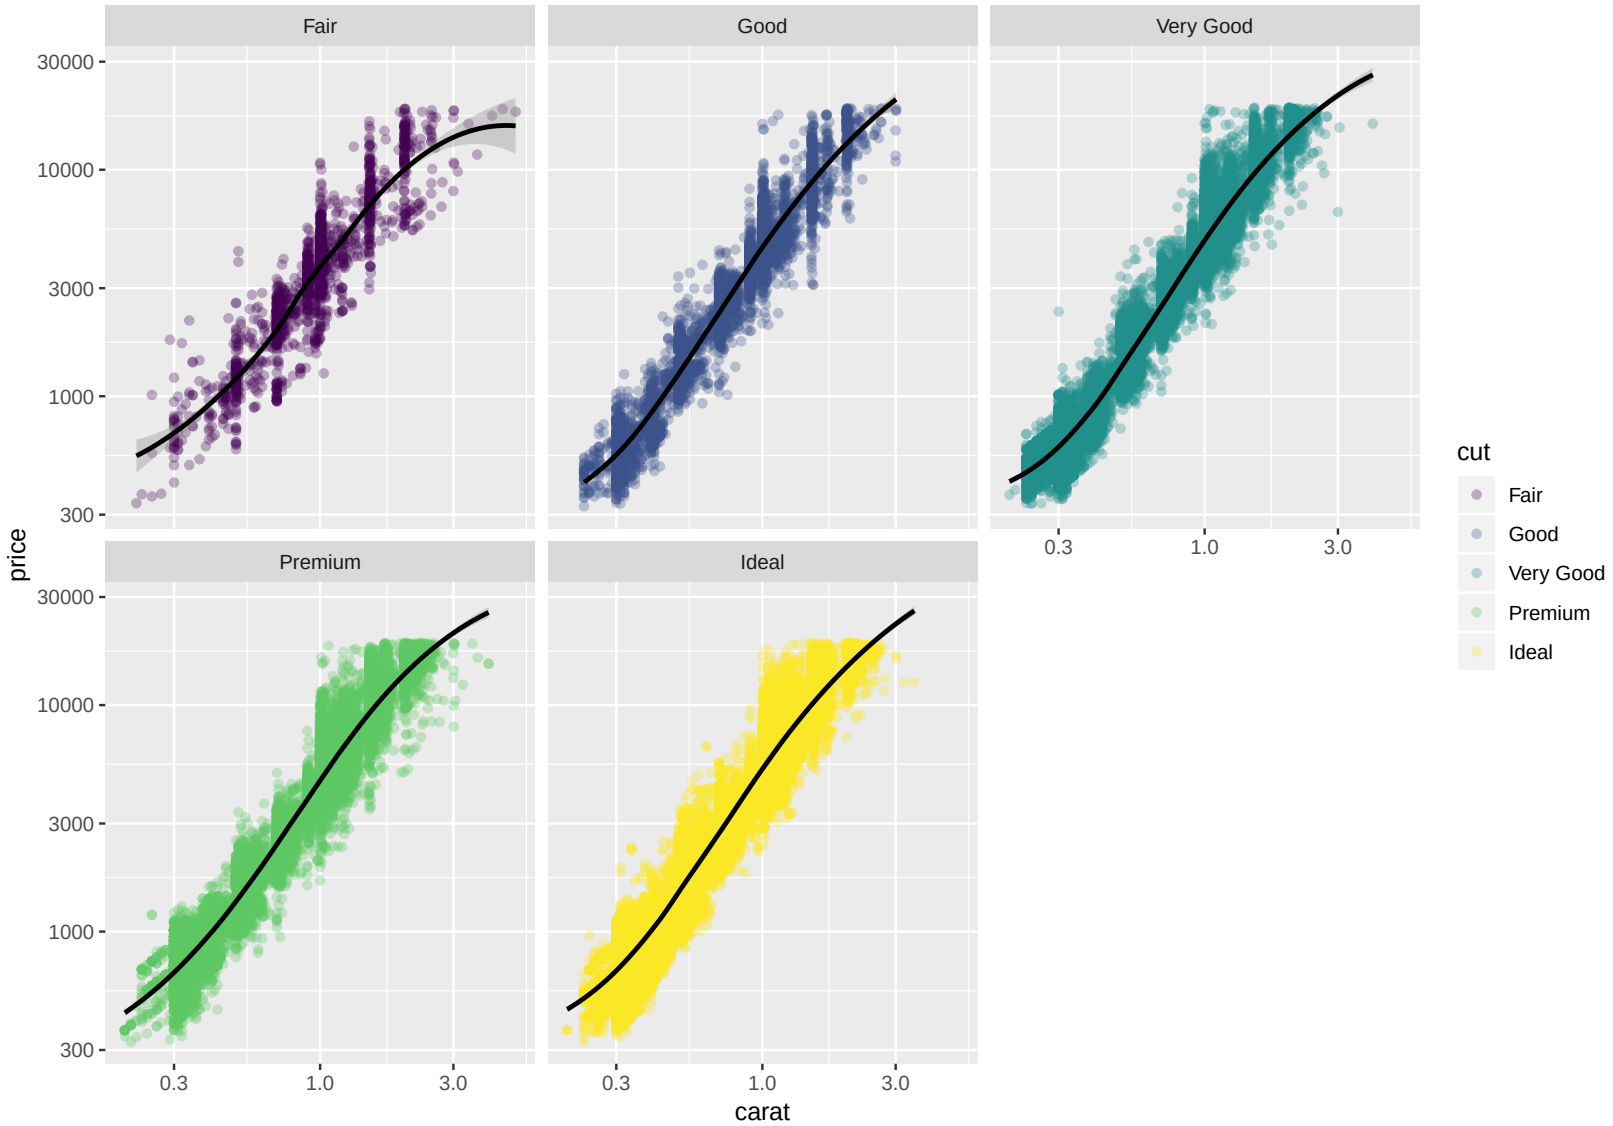

Otras geometrías: density plots

- En muchos casos los gráficos de densidad suelen ser más claros que los histogramas para analizar la distribución de variables cuantitativas.

```
ggplot(small) +
        geom_density(aes(x=price))
```

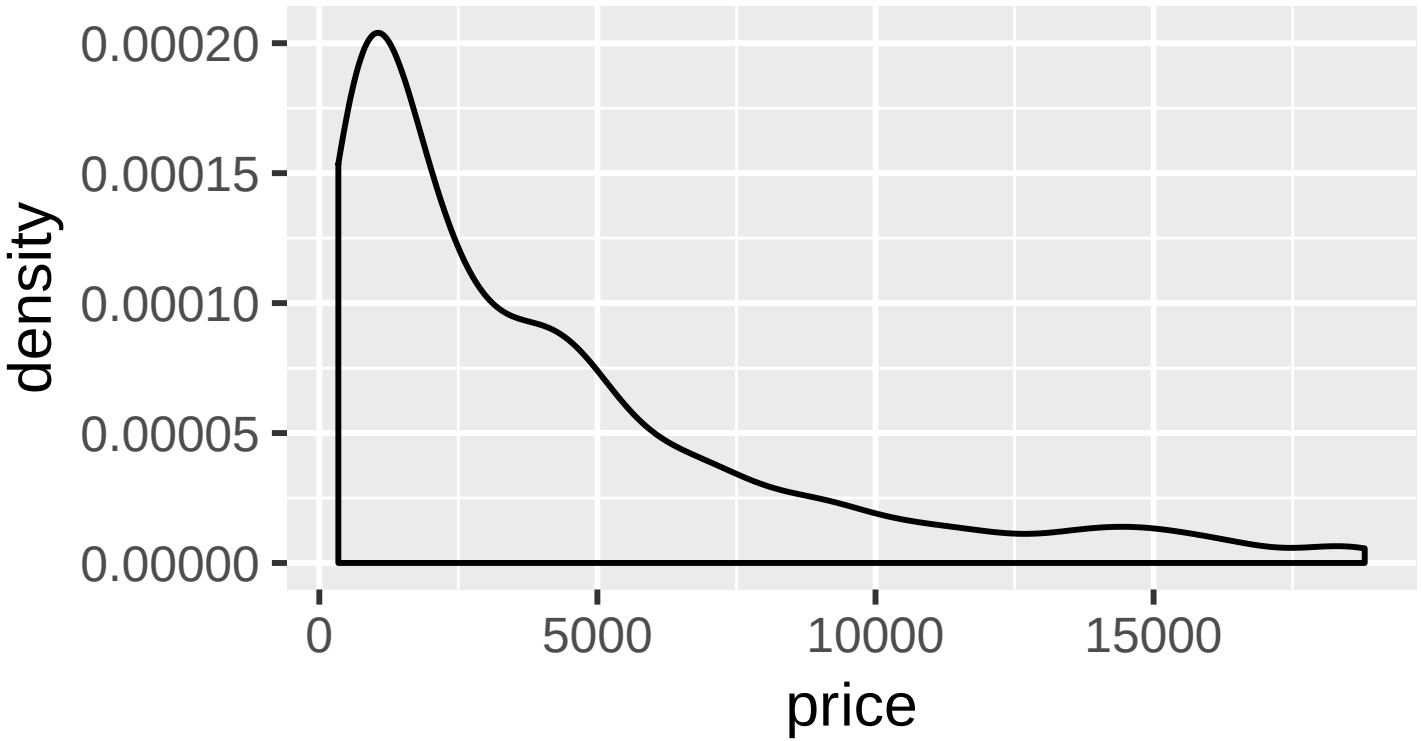

Otras geometrías: density plots

```
ggplot(small) +
        geom_density(aes(x=price, fill=cut))
```

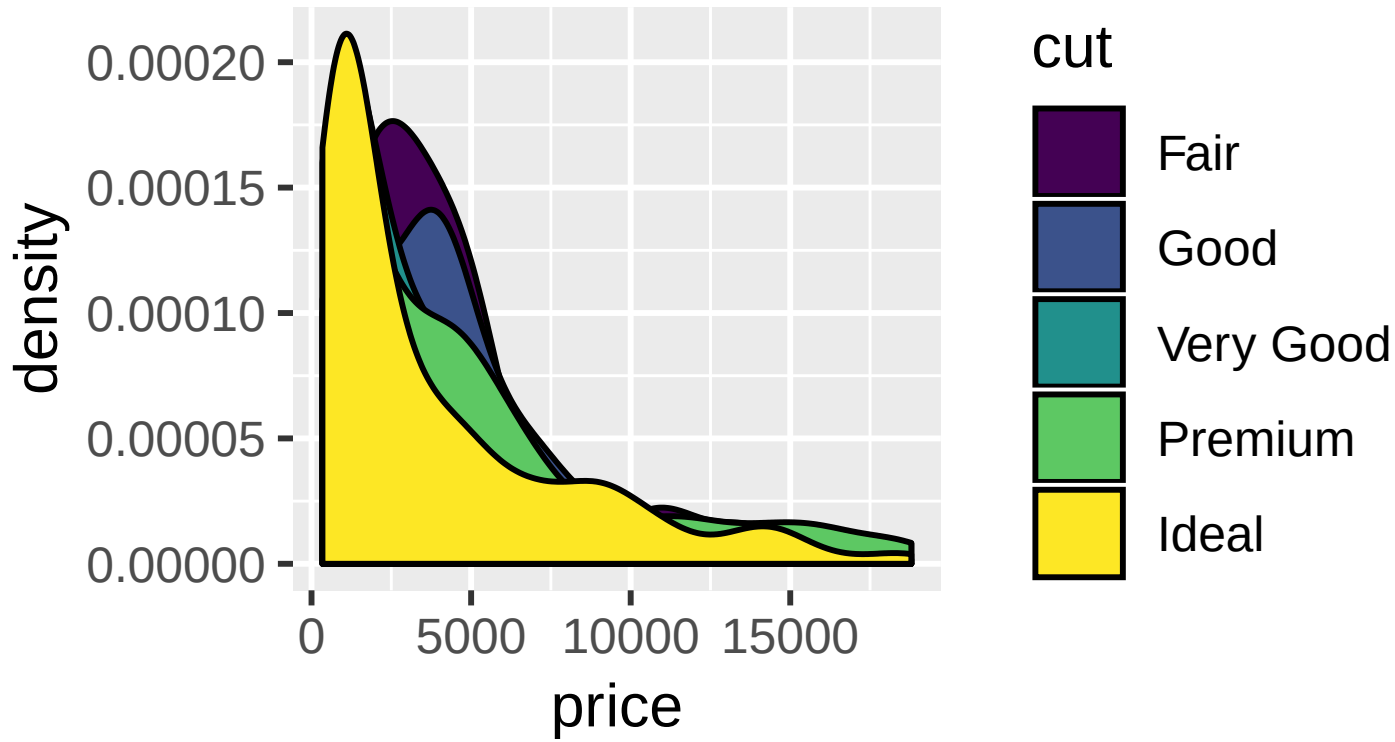

Otras geometrías: density plots

```
ggplot(small) +
        geom_density(aes(x=price, fill=clarity))
```

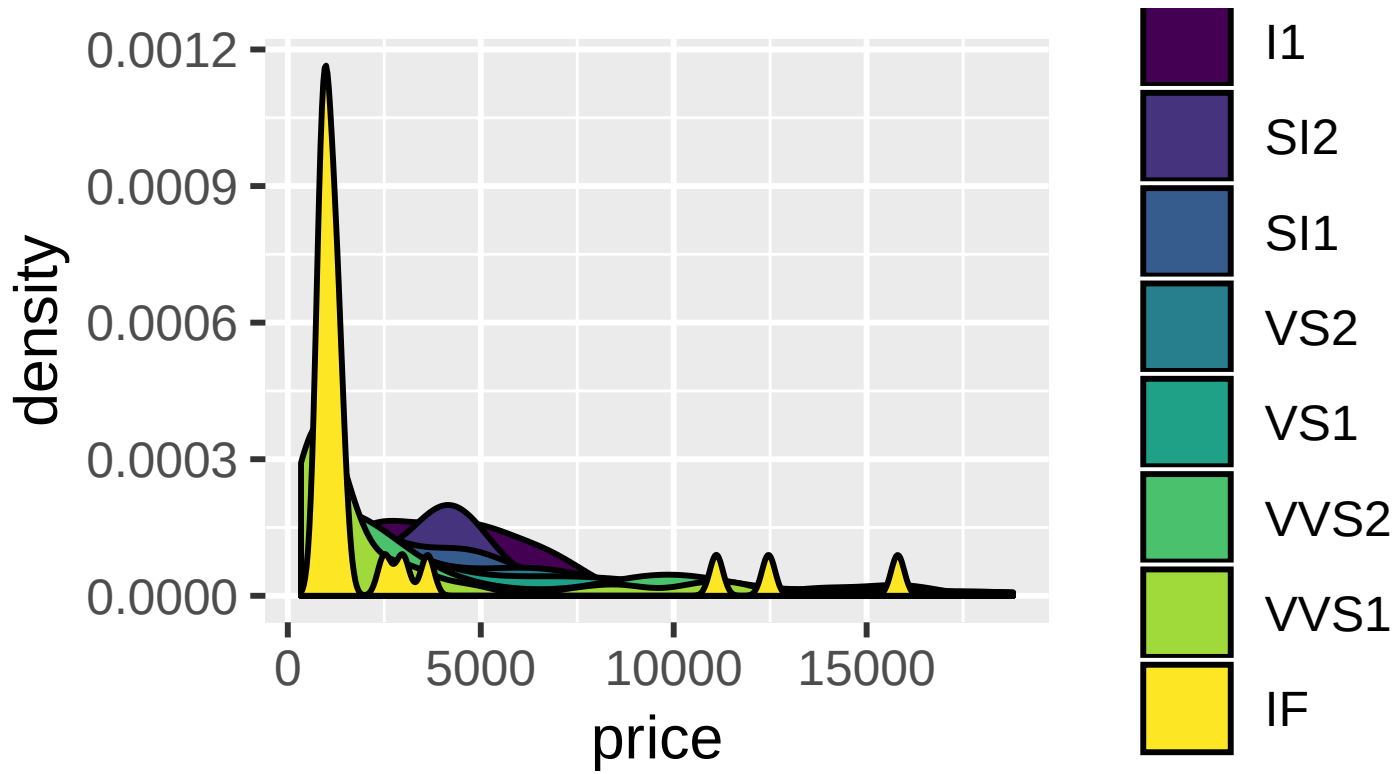

Otras geometrías: density plots

- Podemos usar alguna transparencia para distinguir entre las distribuciones

```
ggplot(small) +
        geom_density(aes(x=price, fill=cut), alpha=0.5)
```

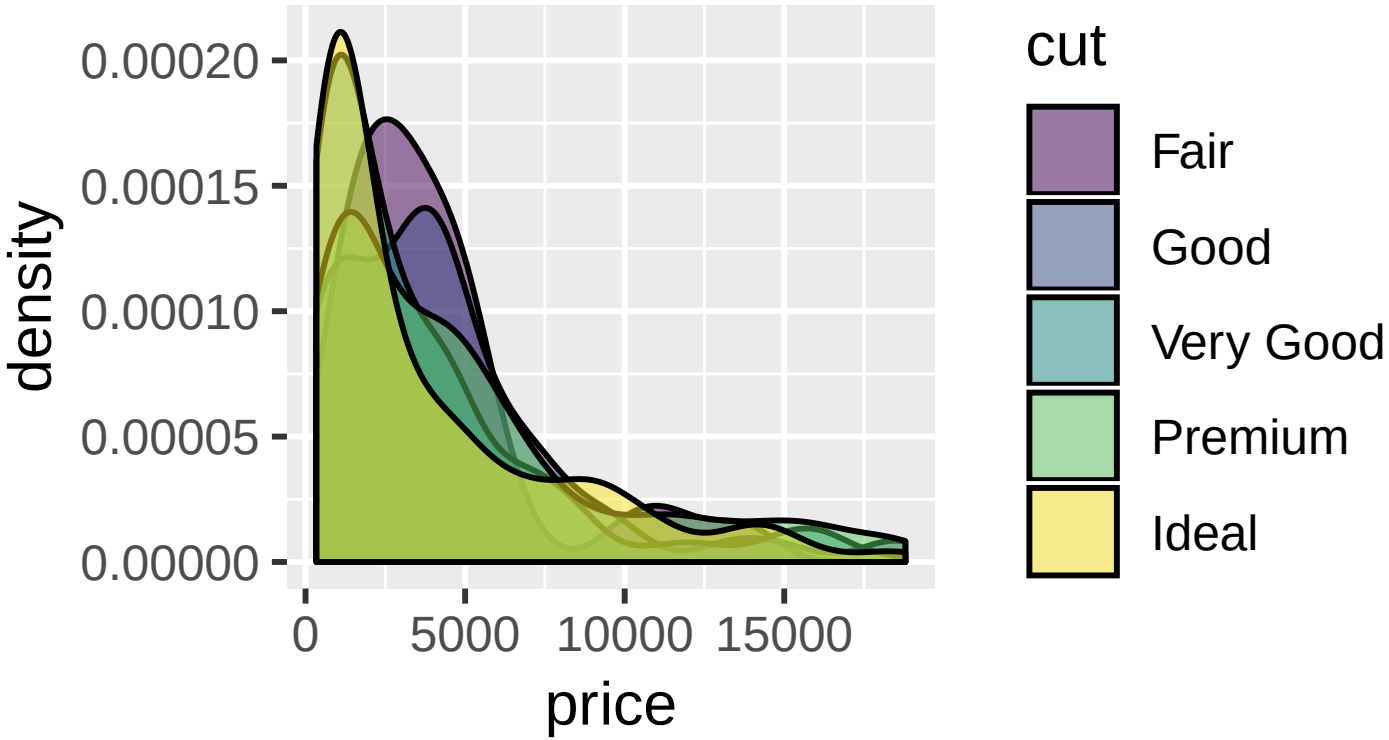

Otras geometrías: density plots

- O usar `colour` en lugar de `fill`

```
ggplot(small) +
        geom_density(aes(x=price, colour=cut))
```

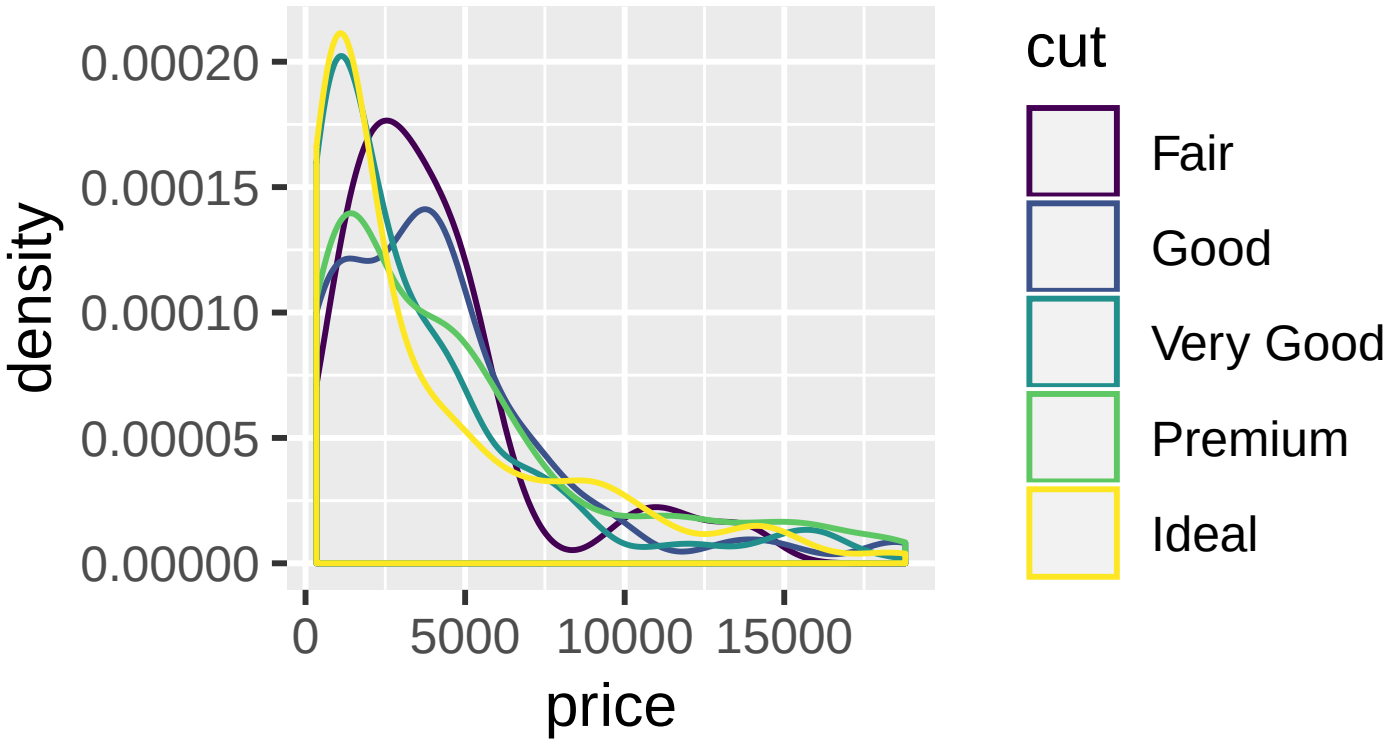

Otras geometrías: box plots

- Se puede usar `geom_boxplot()`

```
ggplot(small)+
        geom_boxplot(aes(x=cut, y=price))
```

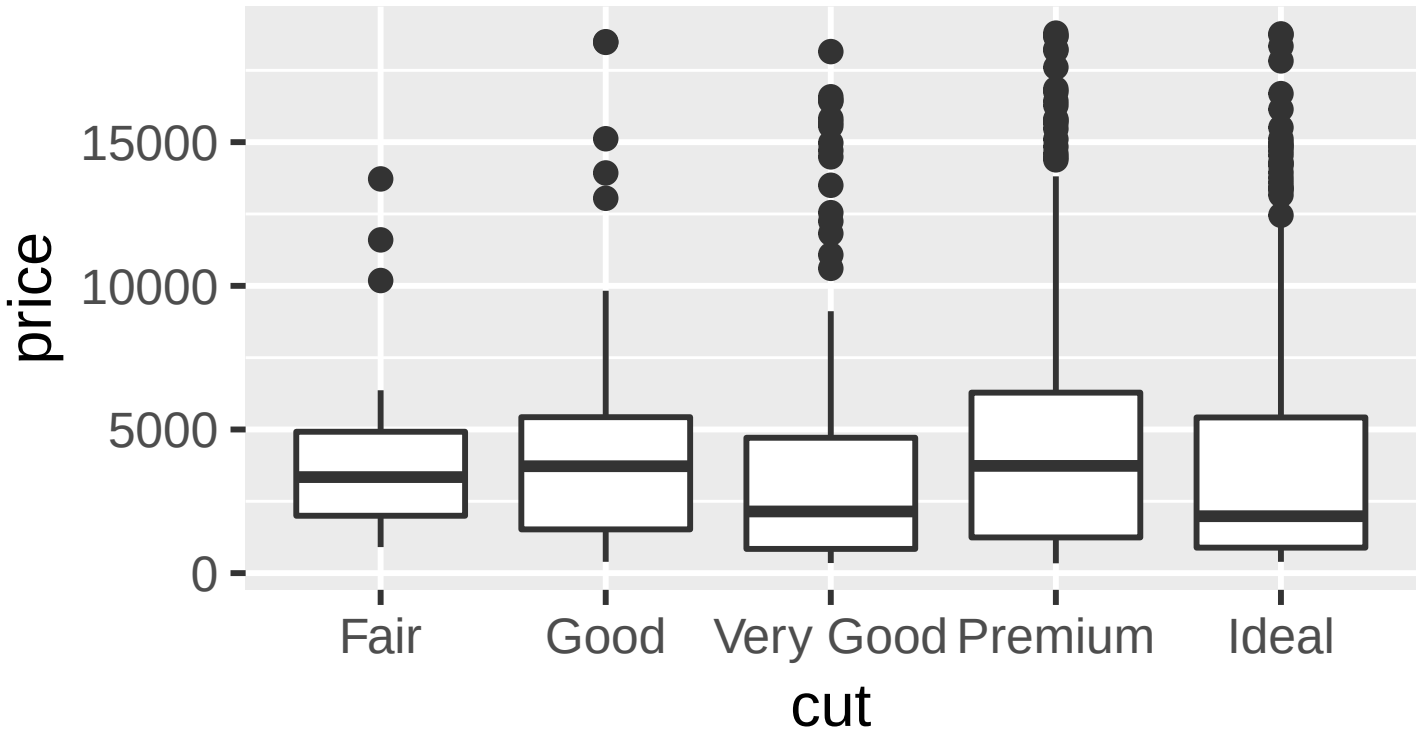

Otras geometrías: box plots

- Al igual que en el módulo base de gráficos de R, podemos confeccionar un boxplot de una variable cuantitativa para diferentes valores de otra variable, simplemente definiendo los parámetros `x=[var1]`, `y=[var2]`.

```
ggplot(small) +
        geom_boxplot(aes(x=cut, y=price, fill=color))
```

Otras geometrías: box plots

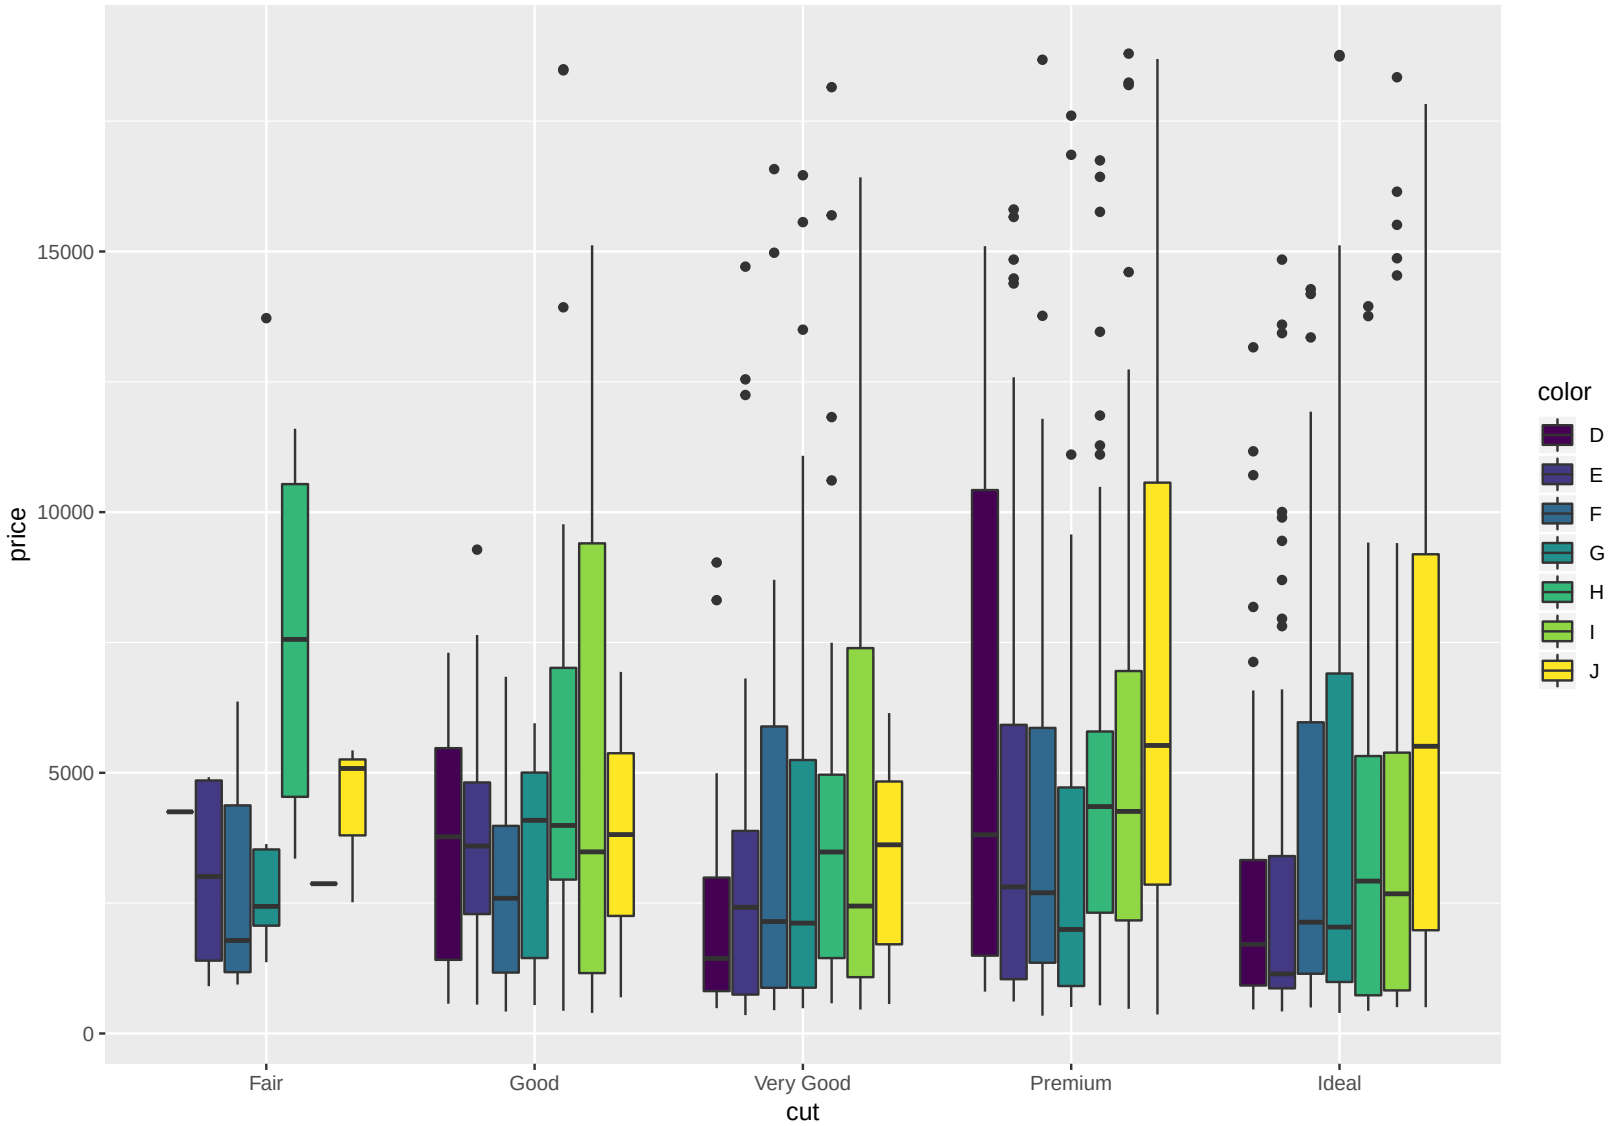

Otras geometrías

- Hay muchísimas otras geometrías para explorar en `ggplot2`
  - geom_abline, geom_jitter, geom_area, geom_line
  - geom_bar, geom_linerange, geom_bin2d, geom_path
  - geom_blank, geom_point, geom_boxplot, geom_pointrange
  - geom_contour, geom_polygon, geom_crossbar, geom_quantile + geom_density, geom_rect, geom_density2d, geom_ribbon
  - geom_errorbar, geom_rug, geom_errorbarh, geom_segment
  - geom_freqpoly, geom_smooth, geom_hex, geom_step
  - geom_histogram, geom_text, geom_hline, geom_tile
  - geom_vline, etc.

Otros recursos:

- Libro de Hadley Wickham.
- Web de `GGplot2`: http://docs.ggplot2.org
- Muchos tutoriales online...